

# Foundation Model을 이용한 MRE 영상에서의 Zero-Shot 장 분할



이영진<sup>1</sup>, 이한상<sup>1</sup>, 서니은<sup>2</sup>, 임준석<sup>2</sup>, 흥헬렌<sup>1</sup>

<sup>1</sup>서울여자대학교 소프트웨어융합학과

<sup>2</sup>연세대학교 의과대학 영상의학교실



## INTRODUCTION

### Clinical Background

- 크론병(Crohn's Disease)은 소화관 만성 염증 질환으로, 치료 반응 평가를 위해 정확한 병변의 위치와 질병 활성도를 정량적으로 평가하는 것이 필수적임.
- 자기공명장운동 검사(MRE)는 방사선 노출 없이 상세한 연부 조직 정보를 제공하는 표준 영상 검사법임.
- MRE 영상에서 질병 활성도를 평가(sMARIA Score)하기 위해서는 장 영역의 정밀 분할이 필수적인 전처리 단계에 해당됨.

### Technical Background

- 장은 복잡한 구조와 심한 형태 변화를 보이며, 특히 주변 장기와의 경계가 불분명해 영상의학과 전문의의 수동 분할에 많은 시간과 노력이 필요함.
- 기존의 U-Net/nnU-Net 기반 완전 지도학습 모델들은 높은 성능을 보였으나, 훈련을 위해 수백 장의 MRE 슬라이스의 **픽셀 단위 전문가 라벨이 필요**하고 그 비용이 높음.
- 최근에는 적은 라벨로도 학습이 가능한 준지도/비지도 학습 접근이 시도되고 있으나, MRE 장 분할에 대한 연구는 아직 보고되지 않음.

### Purpose

- 본 연구는 지도 학습 모델의 한계인 '라벨 데이터의 의존성'을 극복하기 위해 **Zero-Shot 장 분할 접근법을 제안함**.
- 파운데이션 모델 활용 : CT, MRI 등 다양한 영상 시퀀스에서 40개 이상 해부학적 구조 분할을 대규모 사전학습한 MRSegmentator를 활용함.
- MRSegmentator를 추가 학습 없이 그대로 적용하여, 라벨 데이터가 없는 MRE 영상 도메인에 대한 파운데이션 모델의 일반화 성능을 정량적/정성적으로 심층 분석하는 것을 목표로 함.

## METHODS

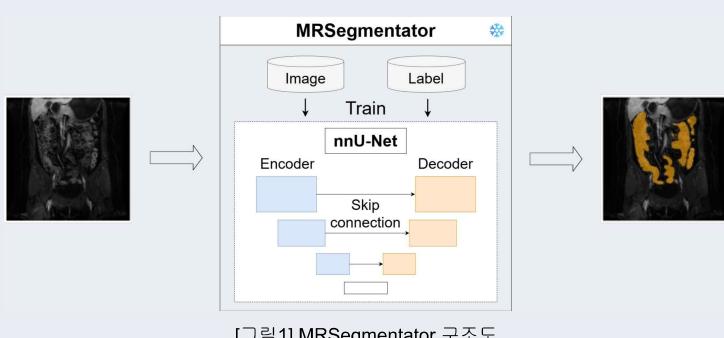
### Foundation Model Overview

본 연구에서는 nnU-Net 아키텍처를 기반으로 한 의료 영상 분할 파운데이션 모델인 **MRSegmentator**를 핵심 도구로 사용함.

- 자동 구성 (Self-Configuring)** : 입력 데이터의 통계적 특성을 기반으로 전처리/네트워크/후처리 파이프라인을 자동으로 최적화하는 nnU-Net의 강점을 그대로 가짐.
- 대규모 사전 학습 및 범용성 : CT와 MRI를 포함한 **2,600건 이상의 대규모 멀티 모달 영상**으로 사전 학습됨. 특히 **40개 이상의 주요 해부학적 구조 분할**을 학습하여, 특정 장기나 영상 유형에 한정되지 않고 안정적인 성능을 발휘함.

### Zero-Shot Segmentation

- 데이터 전처리 : 모든 DICOM 영상을 nnU-Net 입력 포맷인 NIFTI 형식으로 변환하여 입력함.
- Zero-Shot** : MRSegmentator의 사전 학습된 가중치를 추가 학습 없이 크론병 MRE 데이터에 바로 적용하여 분할을 수행함.
- 장 영역 정의 : **small\_bowel(소장)과 colon(대장) 클래스를 합산**하여, 전체 장(bowel) 영역으로 정의함



## RESULTS

### Experimental Setup

- Dataset** : 크론병 환자 208명의 MRE 영상 데이터 (신촌세브란스병원 후향적 수집)
- 영상 특징** : T2 시퀀스, 복부 관상면(Coronal), 3D 볼륨 형태 (환자당 50-120장 2D 슬라이스)
- GT (Ground Truth)** : **10명의 환자 데이터**에 한해 영상의학과 전문의가 구축한 장 영역 수동 마스크 사용.
- 실험 환경** : Python 기반 Google Colaboratory 환경에서 진행.

### Quantitative Results

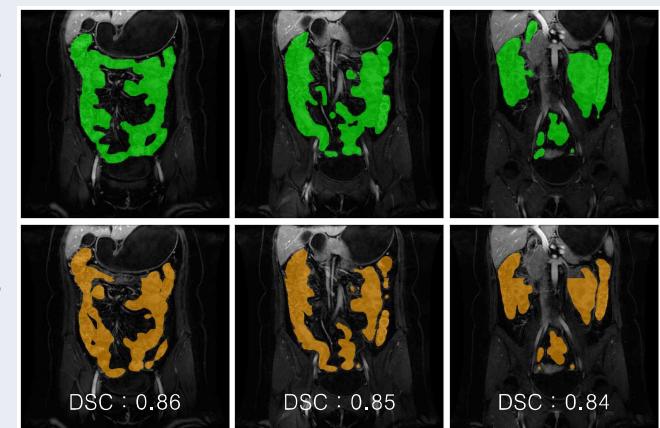
- 평가 개요** : GT가 있는 10명의 환자 데이터에서 총 50장의 2D 슬라이스를 샘플링하여 DSC, 정밀도, 재현율을 평가함.
- DSC (69.5%)** : 추가 학습이나 파라미터 조정 없이 달성한 수치로, 지도학습 모델 대비 낮은 수치이나 Zero-Shot 환경에서 얻은 결과로서 의미가 있음.
- 정밀도 (92.1%)** : 모델이 예측한 영역 대부분이 실제 장 구조에 해당함을 의미함. 사전 학습된 해부학적 지식을 바탕으로 위양성을 최소화하며 신뢰도 높은 분할을 수행함.
- 재현율 (57.0%)** : 상대적으로 낮은 수치로, **과소 분할 (Under-Segmentation) 경향**이 있음을 보여줌.

DSC	Precision	Recall
69.5 ( $\pm 8.2$ )	92.1 ( $\pm 3.8$ )	57.0 ( $\pm 10.2$ )

[표1] 성능 평가 결과 (단위: %)

### Qualitative Results

- 안정적인 분할 : 윤곽이 명확한 장벽 구간 및 장의 중심부에서의 예측이 **GT와 정확히 일치**함.
- 주요 실패 원인 : 정량적 결과(낮은 재현율)에서 관찰된 과소 분할 경향은 주로 경계가 모호하거나 불규칙한 구간에서 **분할이 일부 누락 및 불연속적으로 관찰됨**.
- 의의 : 추가 학습 없이도 분할된 마스크의 위치와 형태가 **일관된 해부학적 패턴을 유지**함을 확인함. 이는 모델이 MRE 장 구조의 형태적 특성을 효과적으로 인식하고 있음을 증명함.



[그림2] MRE 영상에서 장 분할 결과 비교

## CONCLUSIONS

- 본 연구는 의료 영상 파운데이션 모델인 MRSegmentator를 활용해 MRE 영상의 **Zero-Shot 장 분할 방법**을 제안함.
- 추가 학습 없이도 모델이 MRE 장 구조의 해부학적 특성을 안정적으로 인식해, 새로운 의료 영상 도메인에서도 **의미 있는 일반화 성능**이 보임을 확인함.
- 향후 연구에서는 과소 분할 문제를 해결하여 분할 성능을 개선하고, **Zero-Shot으로 얻은 마스크를 바탕으로** 분할 결과의 임상 활용도를 높일 계획임.